

Baseline Report

1 结论与阅读规则

本报告以一张五列总表汇总既有实验，并据 2026 年相关顶会论文确定后续评测覆盖范围。实验记录截至 2026-09-05，文献及报告核查截至 2026-09-13；本次不新增训练、策略评测或数据采集。

核心判断：标准 LIBERO 作为正确性与性能保持对照，不承担主要提升证据；LIBERO-Plus 承担扰动下的主动验证与恢复；MIKASA-Robo 的记忆任务承担独立仿真的时序证据评测；SAFE-DROID 承担真实轨迹上的外部失败检测。MIKASA-Robo 是本次选出的待接入评测，不是已经复现完成的数据集。

“2026 顶会大多需要三个数据集”没有得到本次样本支持。8 篇相关主会论文在统一口径下使用 2-3 个仿真 benchmark：5 篇为 2 个、3 篇为 3 个，并各有真机实验。该小规模定向核查不是全年论文普查，更不是投稿硬性要求。

harness 在本报告中指模型外部的执行与评测机制：输入封装、历史管理、工具调用、阈值、动作循环、恢复及成本记账。模型本身的记忆或注意力不等于外部主动证据获取。当前实验中没有已完成的“预算路由 + 代码迭代”新方法成绩。

SR 与 accuracy 用百分数；AUROC / AUPRC 用 0-100 尺度，不是任务成功率。本次 SAFE 的 $\pm$ 为 3 种子均值与样本标准差，论文 $\pm$ 沿用原文；WCM 保留原始尺度。SAFE 主表取 early-stop 窗口内最大风险分数，成败轨迹均截到每任务最短轨迹长度；该指标不等于实际检测提前量或恢复收益。

NR 表示未在核查论文中定位到对应数据域/协议的报告值；N/A 表示该行根本不是论文模型性能指标。缺项不填 0，不从柱状图目测编造精确值。

左右两列并排用于追溯，不自动表示公平的同协议复现：OFT/AVA 的试验规模不同；SAFE 的超参数搜索范围不同；Plus 的旧诊断协议存在提示词混杂。所有这些差异在 harness 与复现列中显式披露。

2 Baseline 五列总表

表 1: 既有实验总表：论文报告与本项目实际运行分别列示。

dataset	model	harness	reported performance (in paper)	our reproduced performance
A. 策略闭环：有限规模				
LIBERO Spatial	OpenVLA-OFT	H1: 作者策略循环；双相机 + 本体；10 任务 × 5 初态；无外加验证/恢复。	SR 97.6%；Spatial 专用策略。[1]	SR 100.00% (50/50)；每任务 5 次，不是论文 50 次。
LIBERO Spatial	AVA-VLA	H1: 作者策略循环；双相机 + 本体；10 任务 × 5 初态；无外加验证/恢复。	SR 97.4%；四套件联合策略。[2]	SR 96.00% (48/50)；每任务 5 次，不是论文 50 次。
B. OOD：旧实现诊断，不进入主结果				
LIBERO-Plus Spatial 子集	OpenVLA-OFT	H2: 七轴各 10 次；两策略同名单；保留上游提示词混杂。	全套件 SR 69.6%；仅作背景参照，非本批 Spatial 子集。[4]	SR 82.86% (58/70)；诊断值，不作论文优劣比较。
LIBERO-Plus Spatial 子集	AVA-VLA	H2: 七轴各 10 次；两策略同名单；保留上游提示词混杂。	NR: AVA 论文未报告本批 Plus 协议。[2]	SR 78.57% (55/70)；诊断值，不作论文优劣比较。
C. 失败检测：固定配置，未见任务				
SAFE rollout OpenVLA / WidowX	SAFE-LSTM	H3: 白盒特征；3 种子；1,000 epoch；按任务划分；仅评分/校准，不干预。	NR: 原论文未列出 WidowX 域数值。[5]	未见任务 AUROC 62.78 ± 0.99；AUPRC 73.98 ± 2.30。
SAFE rollout OpenVLA / WidowX	SAFE-MLP	H3: 白盒特征；3 种子；1,000 epoch；按任务划分；仅评分/校准，不干预。	NR: 原论文未列出 WidowX 域数值。[5]	未见任务 AUROC 81.85 ± 3.67；AUPRC 87.34 ± 3.84。
SAFE rollout OpenVLA / WidowX	Cosine kNN	H4: 同 H3 划分；固定 k=5；训练轨迹建库，无梯度训练。	NR: 原论文未列出 WidowX 域数值。[5]	未见任务 AUROC 63.64 ± 7.51；AUPRC 67.61 ± 7.32。
SAFE rollout OpenVLA / WidowX	Euclidean kNN	H4: 同 H3 划分；固定 k=5；训练轨迹建库，无梯度训练。	NR: 原论文未列出 WidowX 域数值。[5]	未见任务 AUROC 53.67 ± 6.92；AUPRC 64.45 ± 7.30。
SAFE rollout OpenVLA / WidowX	RND	H5: 同划分；3 种子 × 200 epoch；小尾批合并；仅检测，无恢复。	NR: 原论文未列出 WidowX 域数值。[5]	未见任务 AUROC 49.41 ± 4.01；AUPRC 59.56 ± 4.96。
SAFE rollout Pi0-FAST / DROID	SAFE-LSTM	H3: 白盒特征；3 种子；1,000 epoch；按任务划分；仅评分/校准，不干预。	未见任务 AUROC 58.70 ± 4.37；Real Franka 列，论文调优配置。[5]	未见任务 AUROC 53.58 ± 2.08；AUPRC 53.93 ± 4.75。

续下页

表 1 (续)

dataset	model	harness	reported performance (in paper)	our reproduced performance
SAFE rollout Pi0-FAST / DROID	SAFE-MLP	H3: 白盒特征; 3 种子; 1,000 epoch; 按任务划分; 仅评分/校准, 不干预。	未见任务 AUROC 64.16 ± 5.88 ; Real Franka 列, 论文调优配置。[5]	未见任务 AUROC 53.53 ± 4.45 ; AUPRC 61.34 ± 3.01 。
SAFE rollout Pi0-FAST / DROID	Cosine kNN	H4: 同 H3 划分; 固定 k=5; 训练轨迹建库, 无梯度训练。	未见任务 AUROC 59.51 ± 5.76 ; Real Franka 列, 论文调优配置。[5]	未见任务 AUROC 49.43 ± 3.57 ; AUPRC 49.19 ± 2.54 。
SAFE rollout Pi0-FAST / DROID	Euclidean kNN	H4: 同 H3 划分; 固定 k=5; 训练轨迹建库, 无梯度训练。	未见任务 AUROC 60.27 ± 4.79 ; Real Franka 列, 论文调优配置。[5]	未见任务 AUROC 53.74 ± 3.97 ; AUPRC 52.60 ± 1.51 。
SAFE rollout Pi0-FAST / DROID	RND	H5: 同划分; 3 种子 $\times 200$ epoch; 小尾批合并; 仅检测, 无恢复。	未见任务 AUROC 45.83 ± 5.10 ; Real Franka 列, 论文调优配置。[5]	未见任务 AUROC 48.87 ± 1.96 ; AUPRC 49.38 ± 0.98 。
D. 图像/时序拼图判断: 作者派生测试集				
SMF-CALVIN 公开 1p 数据	I-FailSense 完整模型	H6: 单视角时序拼图 + 文本; 203 样本; 固定发布权重; 离线投票/解码。	1p accuracy 90.64%; Table I. [6]	Accuracy 90.64% (184/203); 与论文保留位一致。
SMF-CALVIN 公开 1p 数据	I-FailSense LoRA/VLM 组件	H6: 单视角时序拼图 + 文本; 203 样本; 固定发布权重; 离线投票/解码。	1p accuracy 85.71%; Table I. [6]	Accuracy 85.71% (174/203); 与论文保留位一致。
E. 世界模型: 公开小型验证协议				
WCM pick-place val	WCM	H7: 固定公开权重; 18 episode / 1,617 窗口; 值与 下一状态预测。	NR: 未定位同一 quick-val 的误差报告; 论文 RL 成功率不可替代。[7]	Value RMSE 0.380342; MAE 0.196550; Pearson 0.720664; next-state MSE 0.007358。
F. 数据生成与环境检查: 不是模型性能				
ManiSkill3 三任务	官方演示 动作回放	H8: PickCube、 StackCube、 PegInsertionSide 各 3 条; 执行动作, 不逐帧写真值。	N/A: 工程回放, 不是学习 策略论文指标。	9/9 回放成功; 只说明演示可 执行。
ManiSkill3 两任务	FailGen 失败注入器	H9: grasp / trans_x; seed 7/8; 按环境终局判定, 不 把注入直接当失败。	N/A: 不是 AHA 检测准确 率。	8/8 链路完成; 4 成功、4 失 败。

3 结果解释与可改进空间

3.1 固定策略与提升空间

OFT 50/50、AVA 48/50 来自同一组小样本 Spatial 初态，不能据此宣称超过论文，也不能用这一接近满分的协议作为新方法主要卖点。正式对照冻结同一执行策略；比较不加 harness、固定查询、轻量风险触发与预算自适应查询，保持底座、输入权限和恢复动作库一致。

3.2 LIBERO-Plus 的旧分数不回填成修正后成绩

OFT 58/70、AVA 55/70 是有效的执行诊断，但上游把扰动后缀混入部分非语言任务指令。两列分数不能与全量论文分数直接相减。正式协议对非语言轴固定标准任务文本，按预注册名单重新运行；旧证据保持原样。

3.3 SAFE：区分调优缺口与研究缺口

DROID 上论文 Real Franka 列的 MLP AUROC 为 64.16，本次固定配置为 53.53；这不是证明原方法失效，也不能把补齐基线调优当作新方法贡献。WidowX 未在原论文表中给出对应值。已有真实域结果支持继续研究跨任务判断，但 DROID 标签异常、特征选择与校准稳定性仍需在开发/校准划分中处理。[5]

3.4 I-FailSense：对应成绩吻合，结论范围有限

单视角完整模型 accuracy 90.64%，组件 85.71%，均与论文 Table I 的保留位一致。已有固定权重和作者派生划分使其成为最接近论文对应条目的复现。该结果不是未触碰 OOD 保证，也不含可交互视角或恢复；论文的 success-F1 与我们记录的 failure-F1 不直接比较。[6]

3.5 WCM 与数据生成不混排

WCM 公开验证集只含成功轨迹，值误差不能说明失败识别能力。9/9 演示回放和 FailGen 的 8 次注入用于工程验收，不能证明 ManiSkill3 已饱和、AHA 检测有效或主动恢复成功。

3.6 与本研究的区别

已有实验覆盖固定执行策略、被动风险检测、离线视觉判断与短时序预测。新增研究对象是“何时缺证据、查询什么、何时停止或恢复”，并由受约束程序执行决策。代码迭代仅使用训练/开发失败案例；测试反馈不进入代码修改循环。当前报告中的空白属于尚待验证的能力，不是已经获得的增益。

4 2026 顶会的数据集数量核查

纳入范围：与本研究直接相关的记忆、主动感知、鲁棒性、效率及策略改进方法，覆盖 ICLR、ICML、CVPR 2026 主会。只收录有正式会议条目或官方接收信息且能核对实验设置的 8 篇。SAFE 属于 NeurIPS 2025；WCM 属于 2026 预印本参考，二者不进入这个计数样本。

统一规则：只计用于机器人任务结果评测的命名仿真 benchmark；训练语料不计。LIBERO 四/五套件合并，SimplerEnv 的 Bridge/Fractal 合并，RoboTwin 1.0/2.0 合并；有独立任务/划分的派生 benchmark 单列，但不等同于独立仿真平台。真机实验单列，不能叫作第三个公开数据集。

论文	会议	仿真 benchmark	计数	真机与计数说明
HAMLET [10][11]	ICLR 2026	LIBERO; RoboCasa Kitchen; SimplerEnv	3	有；跨基准迁移，不只摘要中的两套
MemoryVLA [8][9]	ICLR 2026	LIBERO; SimplerEnv; MIKASA-Robo	3	有；Bridge/Fractal 合并，不把真机两类任务拆算
SP-VLA [12][13]	ICLR 2026	LIBERO; SimplerEnv	2	有；效率与任务质量同时评测
SimpleVLA-RL [14]	ICLR 2026	LIBERO; RoboTwin 1.0 / 2.0	2	有；若版本分开，原文计 3
Cosmos Policy [15]	ICLR 2026	LIBERO; RoboCasa	2	有；RoboCasa 不是 RoboCasa365
AVA-VLA [2]	CVPR 2026	LIBERO; CALVIN	2	有；四个 LIBERO 套件只计 1
ActiveVLA [16][17]	CVPR 2026	RLBench; COLOSSEUM; GemBench	3	有；三者共享 RLBench 系仿真底座
StableVLA [18][19]	ICML 2026	LIBERO; CALVIN	2	有；多个扰动等级不增加数据集数

统一计数均值 2.375、中位数 2，8/8 落在 2-3 之间。若将 RoboTwin 两版本分开，变为 4 篇用 2 个、4 篇用 3 个，仍不能推出“大多数恰好 3 个”。MemoryVLA 原文把部分协议及真机类别细分为 6 个 benchmark，也不等于 6 个独立数据集。[8][14]

结论不是凑齐三套数据，而是覆盖不同失效机制，并有跨平台或真实域证据。没有实体机器人时，真实离线数据能够补充域外检测证据，但不能替代真机主动观察与恢复实验。本文研究结论将限定在已实际验证的范围。

5 数据集的剩余空间与取舍

“未饱和”在这里指：在明确版本、任务和训练条件下，强基线仍留下可研究的失败空间；不是对某数据集所有任务、所有模型的永久判断。以下论文数字不是最新全社区排行榜，更不是对不同 benchmark 的横向难度排序。

数据集 / 协议	可核验的性能证据	本研究定位	现有状态与边界
LIBERO 标准套件	OFT 四套件均值 97.1%；AVA 联合策略 98.0%；Cosmos Policy 98.5%。[1][2][15]	接近上限：保留控制项，不以 clean SR 单独证明创新。	已有 Spatial 两策略结果；其他套件不是本次全量复现。
LIBERO-Plus	作者 OFT 全套件 69.6%；相机 56.4%、初态 31.9%；作者 mix-SFT 整体 79.5%。[4]	选入：视觉/初态扰动、证据不足与恢复主闭环。	代码、资产与采集接口已有；正式无提示词混杂结果待运行。
MIKASA-Robo MemoryVLA 五任务协议	同表 OFT 28.4%、MemoryVLA 41.2%；记忆相关任务仍有明显空间。[8]	选入：独立 ManiSkill 系平台；评测历史证据检索与部分可观测验证。	已有 ManiSkill 基础，不等于 MIKASA 已安装/复现；需锁定旧协议、数据与权重。
SAFE Pi0-FAST / DROID	论文最佳所列 MLP 未见任务 AUROC 64.16；本次固定配置 53.53。[5]	选入：真实域外部离线失败检测；不是 DROID 全集。	已有 1,464 条原始 rollout、780 条既用筛选数据；标签审计已有。
RoboCasa365	GR00T N1.5 预训练 + 目标全数据微调：atomic 68.5%、composite-seen 40.6%、composite-unseen 42.1%。[22]	保留扩展：明确未接近满分，但控制适配与长时序成本更高。	未作为已完成基线；不把旧 RoboCasa 的 67.1% 当作 365 版成绩。
SMF-CALVIN / SAFE-WidowX	I-FailSense accuracy 90.64%；WidowX 本次 MLP AUROC 81.85。[6]	保留诊断：语义判断、跨策略检测；不额外重复凑主数据集数量。	已完成相应离线基线；不能据此证明交互式工具路由。

6 确定的评测组合与资源边界

主评测组合确定为“两套仿真基准 + 一套真实离线数据”：LIBERO-Plus、MIKASA-Robo、SAFE-DROID；标准 LIBERO 是干净控制项。它覆盖视觉扰动、时序记忆和真实跨任务三种问题，而不是把三个指标不同的分数平均成一个总分。

MIKASA 接入采用 MemoryVLA 论文的五任务协议：ShellGameTouch、InterceptMedium、Remember-Color3/5/9。论文设置为每任务 250 演示、100 评测 episode、 128×128 图像；当前官方仓库已存在 90 任务 VLA 版本，不能将 41.2% 移植成新版本成绩。环境提交、任务 ID、控制器与数据版本一致后才进入数值主表。[8][20][21]

MIKASA 的环境和数据公开，能够复用 ManiSkill 的工程经验，但发布策略/控制适配及状态分叉仍需验收。此项是新的研发接入工作，不是零成本增加第三套数据。仅下载固定五任务所需资源，不默认获取整个新版本数据；底层 privileged state 只供标签和验收，不开放给模型。

历史证据与新观察必须分开：记忆任务中未曾记录的过去画面不能事后“购买”，当前多拍一帧也不一定恢复被遮挡的历史事实。harness 只能检索真实已记录历史，且所有对照遵循相同的缓存、保留和检索成本规则。

SAFE-DROID 只证明真实数据上的检测迁移。既有轨迹不能生成任意视角的物理反事实或真实恢复成功标签；已用 780 条也不能再称作全新未触碰测试。标签异常清理、任务划分与数据使用历史全部显式记录。

RoboCasa365 作为长时序家庭场景扩展，不在当前主线同时增加移动底盘、全套 365 任务或完整大模型重训。其微调后约 40% 的复合任务成绩比接近零分的零样本任务更适合区分验证/恢复能力与底层策略根本不会执行的情况。[22]

7 统一对照与论文使用条件

7.1 同底座、同权限

主闭环固定执行策略。OFT、AVA、MemoryVLA 的换底座比较与同底座加 harness 比较分开。RGB、历史、深度、分割、内部特征分别标注权限；禁止把获得额外特权输入的收益写成路由本身的提升。

7.2 固定可比较的 harness

主对照包含：无附加验证、固定频率/固定多视角、被动 critic 触发、预算自适应证据路由。恢复库、最大动作步数与预算上限一致；增加程序迭代模块时，以同一冻结初始版本作对照，报告迭代调用与执行成本。现有 H1-H9 不等于这些对照已完成。

7.3 按任务根隔离

先固定训练、开发、校准、测试清单及哈希。相同初态根的扰动、观察分支与恢复分支不能跨集合。程序生成只使用开发反馈；测试时冻结代码。自演化训练预算与部署期查询预算分开记账。

7.4 报告真正相关的结果

闭环按数据集分别报告任务 SR、失败恢复 SR、误干预率、证据调用数、GPU 秒及 p95 延迟。检测使用相同时间窗、相同正类的 AUROC/AUPRC、固定误报水平下的检出率与提前量。拒判同时报告覆盖率，不把“少报警”当作“更安全”。

7.5 难度与公平性验收

在开发集检查失败是否可观察、可干预，排除基础设施错误与完全不可执行状态。难度和任务名单在最终测试前固定，不根据新方法优势筛选；统计区间按任务/episode 聚类，避免把同一轨迹的多帧当独立样本。

7.6 本报告的完成边界

已有结果足以作为起始基线与方法开发依据，但尚无跨上述主组合、同预算、同输入的完整新方法对照。数据集尚未饱和并不意味着一定存在可由主动观察解决的剩余错误，更不意味着已获得顶会级贡献。

8 证据索引与参考来源

表中所有 our reproduced performance 来自仓库已有结果，不来自论文或新模拟数字。生成脚本从原始汇总 JSON 重算 SAFE 均值/样本标准差，并保存每个输入文件 SHA-256 与表行对应关系。

H1/H2 的详细协议见 OPENVLA_AVA_VLA.md、LIBERO_PLUS.md；H3-H5 见 SAFE_20260905.md、SAFE_DROID_20260905.md、EXTENDED_BASELINES_20260905.md、SAFE_RND_20260905.md；H6-H9 见 IFAILSENSE_20260905.md、WCM.md、MANISKILL3.md、AHA_FAILGEN.md。这些历史明细保留，不因总报告替换而删除。

ActiveVLA、AHA、ADV/VeGAS、VAP-TAMP、Thea、Self-Harness/Zetta 不列为已完成数值基线。旧状态审计仍保留其日期；本次特别复查 ActiveVLA 官方入口仍为待发布，因此不能将 AVA-VLA 的结果代替 ActiveVLA。[23]

- [1] OpenVLA-OFT: 原论文 Table I (2025)
- [2] AVA-VLA: CVPR 2026, Table 1、Table 2 与真机实验
- [3] LIBERO-Plus: CVPR 2026; 原论文结果表
- [4] LIBERO-Plus: 作者论文完整表与各套件明细
- [5] SAFE: NeurIPS 2025, Table 8、B.8 与真实 Franka 实验
- [6] I-FailSense: Table I 与评测定义
- [7] WCM: 作者公开 quick benchmark、数据与权重
- [8] MemoryVLA: ICLR 2026; 4.1-4.5, Table 4
- [9] MemoryVLA: 作者 ICLR 2026 项目与公开资源
- [10] HAMLET: ICLR 2026; Tables 2-3、真机实验
- [11] HAMLET: ICLR 2026 正式会议条目
- [12] SP-VLA: ICLR 2026 正式会议论文
- [13] SP-VLA: 实验设置与真机补充
- [14] SimpleVLA-RL: ICLR 2026, 3.1 实验设置
- [15] Cosmos Policy: ICLR 2026 正式会议条目
- [16] ActiveVLA: CVPR 2026 正式会议论文
- [17] ActiveVLA: 4.1 与三套仿真基准
- [18] StableVLA: ICML 2026; Table 1 与真机设置
- [19] ICML 2026 官方论文列表 (含 StableVLA)
- [20] MIKASA-Robo: 官方数据、环境与版本说明
- [21] MIKASA-Robo: 90 任务 VLA 版与旧 RL 版发布边界
- [22] RoboCasa365: Table 2, 目标任务微调后的成功率
- [23] ActiveVLA: 本次核查仍待发布的代码与评测入口