

Baseline 复现、测试 与分析报告

1 结果总览与证据等级

本报告汇总截至 2026 年 9 月 5 日已完成的本地及服务器实验，服务于“预算约束主动多模态证据获取、VLA 验证与失败恢复、跨分布泛化”研究。数据来自实际日志、逐轨迹记录、独立测试和校准表，不以论文原始成绩替代本项目实测值。

工作	完成程度	已获得证据
OpenVLA-OFT	有限协议	原版 Spatial：50/50 成功；公开权重闭环评测。
AVA-VLA	有限协议	同一组 Spatial：48/50 成功；不是 ActiveVLA。
SAFE / WidowX	固定配置	LSTM、MLP 各 3 种子、1,000 epoch；测试与校准。
SAFE / DROID	固定配置	同上；增加标签异常审计及敏感性测试。
WCM	公开子集	pick-place 官方验证集：18 条轨迹、1,617 窗口。
LIBERO-Plus	实现诊断	七维各 10 次；提示词混杂使其不进入主 OOD 表。
ManiSkill3 / FailGen	链路验证	官方动作回放、失败注入及实际终局结果。
SAFE 距离型	固定配置	cosine、Euclidean 两域各 3 种子，共 12 组。
SAFE RND	固定配置	两域各 3 种子、200 epoch，保存后加载评测。
I-FailSense	公开检查点	CALVIN 单视角 203 样本，完整模型及组件对照。
其余参考工作	未达定量复现	缺失可执行资源或完整运行条件，详见资源核查。

1.1 等级与使用规则

L3 指在声明的配置及数据上得到可追溯定量结果；L2 指真实模型、数据或环境完成端到端执行；L1 为源码、接口或依赖核验；L0 为关键实现缺失、尚未复现。L3 不自动等于整篇论文全任务、全参数网格的复现。

策略成功率、失败检测 AUROC、世界模型误差分别回答不同问题，本报告不混排。现有结果尚非本项目新方法的统一主表：输入权限、数据域、训练范围、预算和恢复能力仍有差异。

1.2 当前核心结论

标准 Spatial 小样本成绩接近饱和；SAFE 的跨任务排序和报警校准存在明显域依赖；DROID 固定配置并未获得强泛化结果。以上是基线现象，不是本项目已解决的问题，也不能据此保证新方法创新或投稿结果。

证据：复现状态总表及各工作分项记录

2 固定执行策略：OpenVLA-OFT 与 AVA-VLA

2.1 实验协议

采用原版 LIBERO Spatial 的 10 个任务，每任务前 5 个官方初始状态，共 50 次。两策略使用相同任务、提示词及初始状态。策略种子为 7；上游环境种子固定为 0。环境图像为 256 像素，双相机与本体状态输入，动作块为 8 步，稳定等待 10 步，任务执行上限 220 步。

策略	成功数	成功率	Wilson 95% 区间
OpenVLA-OFT	50/50	100%	[92.87%, 100%]
AVA-VLA	48/50	96%	[86.54%, 98.90%]

上述区间只作描述性参考；轨迹按任务聚集，不满足简单独立样本的全部解释条件，不能据此宣称显著优劣。两者均成功 48 次，仅 OFT 成功 2 次。

2.2 可比较与不可归因的部分

OFT 使用 Spatial 专用发布权重；AVA 使用四套件联合权重。训练范围不同，不能把观测到的差异全部归因于主动注意力、历史特征或结构设计。AVA-VLA 与 ActiveVLA 是不同工作。

两者都使用公开策略权重，本轮未重新训练这两个 7B 级策略。有限 50 次评测也不是官方每任务 50 次的完整评测规模。

2.3 工程核对与效率边界

标准 LIBERO 与 LIBERO-Plus 已隔离安装并核对实际导入路径；早期错误入口的试跑未纳入正式汇总。标准与扰动共 240 次策略执行的配对审计通过，没有基础设施错误。

已保存策略调用次数、推理耗时与显存记录，但部分运行与其他任务共享 GPU，不能作为严格的算法延迟对比。效率主表需要在相同负载、预热、重复测量及计费口径下重新测量；离线采集全部候选证据的耗时不等于在线路由实际成本。

2.4 在本研究中的位置

OFT 固定为主执行策略，AVA 作为另一策略接口及视觉注意力参考。验证器的贡献要在同一冻结策略上衡量，并分别报告检出率、误报、恢复收益和成本，不能仅用接近饱和的标准成功率替代。

证据：策略协议、权重范围及运行边界

证据：逐例配对审计

3 LIBERO-Plus: 七维扰动实现诊断

固定子集按七类扰动各抽 10 个任务、每任务执行一次。抽样种子 20260905, 策略种子 7, 环境种子 0。两个策略共享同一名单; 不根据成绩选择任务。

扰动类别	OFT 成功数	AVA 成功数
背景纹理	10/10	10/10
相机视角	9/10	6/10
语言指令	7/10	8/10
光照条件	10/10	10/10
物体布局	9/10	9/10
机器人初始状态	3/10	4/10
传感器噪声	10/10	8/10
合计	58/70 (82.86%)	55/70 (78.57%)

逐例配对: 两者均成功 50 次, 仅 OFT 成功 8 次, 仅 AVA 成功 5 次, 两者均失败 7 次。140 次执行均无基础设施错误。

3.1 关键协议问题

上游提示词生成会将部分非语言扰动的文件名后缀写入指令, 例如 view、initstate、table 等。因而图像或初态变化时, 语言输入也可能改变。本批保留发布实现行为并记录实际提示词, 可以复核实现, 但不能做严格的单一视觉因素归因。

本表属于实现诊断, 不进入论文主 OOD 对照。后续采集接口已按标准 BDDL 指令处理非语言变体, 但修正后的七类小型执行检查不是这 70 次成绩的重测, 不能把两个版本拼接。

3.2 分析结论

本子集中机器人初始状态变体失败较多; 这只反映当前样本与设置, 不等于整个套件最难维度的排名。小样本、任务构成和提示词混杂限制了泛化解释。

主 OOD 协议必须保留提示词版本、原生变体身份、初态根及扰动轴, 区分单轴变化与任务和扰动同时变化。当前未完成四套件全量、多种子评测; 10,030 个变体索引不是 10,030 次已执行实验。

证据: 七维分项结果及提示词混杂审计

4 SAFE: OpenVLA / WidowX 失败检测

4.1 训练、输入与划分

使用作者发布的 532 条轨迹、8 个任务，策略内部 token 特征取均值，输入为 4,096 维白盒表征，不是仅靠外部 RGB 的黑盒检测器。每次留出 2 个未见任务；官方 unseen-task 比例 0.25、seen-train 比例 0.66。精确路径与任务隔离检查通过。

LSTM、MLP（官方 indep）各运行种子 0、1、2，每次 1,000 epoch；batch 64，学习率 10^{-4} ；正则分别为 0.001 和 0.01。其余结构、损失使用官方默认，不做全数据特征标准化。最终权重重新加载测试，不按未见任务成绩选择 checkpoint，不进行完整网格搜索。

未见任务指标	LSTM	MLP
early-stop AUROC	0.6278 ± 0.0099	0.8185 ± 0.0367
early-stop AUPRC	0.7398 ± 0.0230	0.8734 ± 0.0384
窗口 50% 时刻 AUROC	0.6319 ± 0.0261	0.6172 ± 0.0703
窗口 100% 时刻 AUROC	0.6794 ± 0.0443	0.8185 ± 0.0367

均值及样本标准差来自三个种子，包含任务划分及训练随机性的变化。失败为正类；AUPRC 为官方曲线积分，不是 average precision。early-stop 是该任务最短轨迹长度定义的统一窗口内最大分数，并不代表已经找出最早可干预时点。

4.2 校准与检出结论

在已见任务成功轨迹上校准，nominal $\alpha = 0.10$ ；未见任务窗口末端实测 FPR (at earliest stop, 非窗口内累计报警口径)：

模型	seed 0	seed 1	seed 2
LSTM	4.84%	27.87%	38.71%
MLP	53.23%	1.64%	14.52%

MLP 在累计窗口排序上较好，但在 50% 时刻没有同等优势。跨任务误报率不稳定；低误报也可能对应低检出，例如 LSTM seed 0 的 TPR 仅 7.69%。nominal alpha 不能直接写成 OOD 保证。

证据：完整配置、数据指纹及指标定义

证据：各种子阈值、FPR 与 TPR

5 SAFE: Pi0-FAST / DROID 补充复现

5.1 数据完整性与标签问题

用户下载的 27,370,430,312 字节 ZIP 已上传，双端 SHA-256 一致；74,337 个条目完成解压及 CRC 检查。这是 SAFE 的 Pi0-FAST/DROID rollout、特征与视频包，不是整个原始 DROID 数据集。

原始 1,464 条、13 个任务描述，按作者读取规则计 558 成功、906 失败。审计发现 15 条异常：5 条非二元元数据、10 条二元元数据与文件名不一致。官方复现沿用作者对元数据取 int 的规则，不改原标签。另有 1 条标准腕部视频链接缺失，存在非标准命名记录，未擅自改名。

官方 full-length、任务内成败平衡与最多 60 条的筛选后，使用 780 条（390 成功、390 失败）。每种子 train 450、val_seen 150、val_unseen 180；训练 10 任务、未见 3 任务。输入为 2,048 维 pre-logits token 均值，不能与 WidowX 特征混用。

5.2 实际结果

两种结构、三个种子各训练 1,000 epoch，其余固定配置与前节一致。六组最终权重独立复核通过，对应 AUROC/AUPRC 与训练结束记录最大差为 0。

未见任务指标	LSTM	MLP
early-stop AUROC	0.5358 ± 0.0208	0.5353 ± 0.0445
early-stop AUPRC	0.5393 ± 0.0475	0.6134 ± 0.0300
窗口 100% 时刻 AUROC	0.5768 ± 0.0471	0.5353 ± 0.0445
排除异常后 early AUROC	0.5387 ± 0.0205	0.5361 ± 0.0455

敏感性测试沿用原训练权重，仅排除评测与校准中的异常，不是清洗后重训。8 条异常进入官方筛选集合；种子 0 的未见集不移除，种子 1、2 各移除 1 条；各校准集移除 2 条。该检查不能排除训练标签异常的影响。

$\alpha = 0.10$, 窗口末端 FPR / TPR	seed 0	seed 1	seed 2
LSTM	.2222 / .2889	.0889 / .2222	.3444 / .3667
MLP	.2889 / .3222	.1556 / .2667	.2667 / .3444

当前配置下跨任务排序接近随机，不能据此否定 SAFE 全部配置；没有对测试集反复调参。两域分别训练，不是 WidowX 到 DROID 的零样本迁移。15 条异常已从新管线的可靠外部监督候选中隔离。

证据：补充复现、哈希、独立测试与敏感性结果

6 补充对照：SAFE 距离型检测器

6.1 补充范围与固定协议

使用 SAFE 官方 EmbedModel，分别建立 cosine 与 Euclidean 距离的 $k = 5$ 近邻基线；WidowX、DROID 各运行三个既定种子，共 12 组。沿用此前相同轨迹筛选、任务划分、特征输入与指标函数，不根据测试成绩调整距离或 k 。

成功和失败特征库只来自训练轨迹的有效时间步，风险分数为到成功库与失败库的距离之差。不开启累计求和，不进行全数据标准化。该模型建立特征库而非梯度训练，不能写作训练了 1,000 epoch。

数据域	距离	early AUROC	early AUPRC
WidowX	cosine	.6364 $\pm$.0751	.6761 $\pm$.0732
WidowX	Euclidean	.5367 $\pm$.0692	.6445 $\pm$.0730
DROID	cosine	.4943 $\pm$.0357	.4919 $\pm$.0254
DROID	Euclidean	.5374 $\pm$.0397	.5260 $\pm$.0151

指标仍为未见任务统一窗口内最大风险分数的 AUROC / AUPRC，均值及样本标准差来自三个种子。这些是预先固定配置的结果，不是原论文全部参数网格的最优值。

6.2 独立复核与校准

每组实际训练特征库单独保存并记录 SHA-256；重新加载后，对完整 val_seen、val_unseen 逐轨迹分数复核，12 组最大差均为 0。训练库检索自身造成的训练分数优势不用于泛化结论。

在成功轨迹上按 $\alpha = 0.10$ 校准后，窗口末端未见任务 FPR 范围为：WidowX cosine 6.45%–30.65%，Euclidean 9.68%–77.05%；DROID cosine 5.56%–13.33%，Euclidean 6.67%–17.78%。这些是末端时刻误报，不能写成窗口内累计误报保证。

6.3 分析结论

简单距离型对照已补齐。WidowX 的 cosine 在当前三种子均值上低于既有 MLP；DROID 两种距离的窗口累计排序仍较弱。未作显著性检验，不据小样本均值宣称所有配置的模型优劣。距离分数没有利用外部主动视觉证据，是后续判断新增查询是否产生收益的基础对照；特征库检索成本仍需统一实测。

DROID 已追加固定特征库下的标签异常排除敏感性检查；未清洗训练库重建，因而不能排除训练标签问题的影响。

证据：补充配置、各种子结果、校准与复核

7 补充对照：SAFE RND 检测器

7.1 训练与复核

沿用 SAFE 官方 RND 网络及损失，WidowX、DROID 各训练种子 0、1、2，共六组，每组 200 epoch。学习率 10^{-4} 、Adam、weight decay 0.01，成功与失败样本均参与；数据筛选及划分与此前基线逐路径一致。

名义 batch 为 32。为降低显存占用并避免极小尾批只有单类、导致作者损失的分类均值出现 NaN，将不足半个 batch 的尾批并入前一批。每轮保留全部训练轨迹，网络及损失不变；这属于明确披露的 batch 工程调整，不是完整官方参数网格复现。

六组最终权重重新加载后完成全划分评测；各组首条 val_seen 轨迹的保存前后预测差为 0。DROID 另从已保存逐时间步预测独立重算全部标量指标，最大差为 0；该检查不冒充第二次完整模型前向。

未见任务指标	WidowX	DROID
early-stop AUROC	.4941 $\pm$.0401	.4887 $\pm$.0196
early-stop AUPRC	.5956 $\pm$.0496	.4938 $\pm$.0098
窗口 50% 时刻 AUROC	.5316 $\pm$.0680	.4975 $\pm$.0183
窗口 100% 时刻 AUROC	.5754 $\pm$.0705	.5955 $\pm$.0324

7.2 低误报不等于有效检出

以下改用窗口内曾经报警口径 (by earliest stop)，对窗口内最大分数校准及测试；不是前述末端时刻 FPR 表。校准仍仅使用已见任务成功轨迹， $\alpha = 0.10$ 。

窗口累计 FPR / TPR	seed 0	seed 1	seed 2
WidowX	.0484 / .0288	.0000 / .0000	.0000 / .0115
DROID	.0667 / .0556	.0778 / .0556	.0778 / .0556

当前累计排序接近随机，累计报警的低 FPR 同时伴随很低的 TPR。即使末端时刻 AUROC 高于累计口径，也不能据此称为可靠的早期失败检测。此结果保留，不按测试成绩更换训练轮数、距离或权重。

DROID 标签异常排除检查使用同一权重和原始任务窗口，只从校准与测试中移除异常，不是清洗后重训。完整配置、各 epoch 日志、权重哈希及敏感性数值进入仓库记录。

证据：六组训练、独立指标、校准和结果边界

8 I-FailSense：外部视觉失败检测

8.1 固定模型与评测样本

采用作者发布的 CALVIN 1p 模型：PaliGemma2 3B、配套 LoRA 与 epoch 10 FS 分类器。权重在推理前固定；底座授权、文件哈希和压缩包 CRC 检查均通过。

数据为 ACIDE/AHA-Calvin-1p 的 2,022 条 validation，沿用作者 test_size=0.1、seed=42 得到 203 条测试样本，其中失败 97、成功 106。batch 4、FP32，保持作者提示词、特征层、池化及投票逻辑；未重新训练。两个运行均完成全部样本，没有静默跳过。

指标	完整 I-FailSense	VLM 组件
正确数 / 总样本	184/203	174/203
准确率	90.64%	85.71%
平衡准确率	90.47%	85.71%
失败样本正确数	84/97	83/97
成功样本正确数	100/106	91/106
failure AUROC	0.943153	不报告
failure AUPRC	0.958347	不报告

VLM 组件只使用下一 token 硬标签，不调用随机 FS 分类器，不报告连续风险 AUROC。完整模型的加权票数比例不是校准概率；AUPRC 为曲线积分。

8.2 逐例核对与分析

203 个源行号及标签完全一致：共同正确 171 条，仅完整模型正确 13 条，仅组件正确 3 条，共同错误 16 条。准确率增加 4.93 个百分点，主要来自成功样本的误报减少，失败检出仅净增 1 条。

从保存预测重算准确率、平衡准确率、AUROC 和 AUPRC，最大差为 0。本机推理约 10.18 秒，不含加载与数据准备，仅作运行审计。

8.3 数据与论证边界

这是作者 validation 派生的静态图像检测，不是 SAFE 白盒时序任务或 LIBERO 策略成功率。公开训练代码存在使用外部测试资源作模型选择的路径；发布权重的全部训练暴露尚未充分证明，不能称为完全未见 OOD 测试。

该模型作为外部视觉 critic 参考；数据不含主动换视角反事实或可重置恢复分支，不能单凭此结果证明预算查询、跨场景泛化或恢复收益。

证据：固定 revision、完整结果、组件对照与逐例审计

9 WCM 与环境、失败生成链路

9.1 WCM: 公开 pick-place 验证集

使用官方数据、检查点及 episode split, 在 18 条验证轨迹上评测全部 1,617 个时序窗口, 102 个 batch。没有重训 WCM, 也没有复现其论文所有环境。

指标	实测值
value RMSE	0.380342
value MAE	0.196550
value Pearson	0.720664
token value RMSE	0.383271
token value Pearson	0.716935
next-state MSE	0.007358
token next-state MSE	0.007333

上述结果证明公开子集上的时序预测入口与数值复核可用。回归误差不等于失败分类能力; 成功轨迹资源不能单独形成充分的失败/恢复验证集。WCM 后续对照必须在相同任务及失败划分上评测, 不能把此 RMSE 与 SAFE AUROC 排名。

9.2 ManiSkill3 与 FailGen: 不是学习模型成绩

ManiSkill3 的 PickCube、StackCube、PegInsertionSide 三任务, 分别重放 3 条官方 motion-planning 动作, 9/9 成功。该结果验证控制器、RGB-D 渲染及环境终局标签, 不代表 VLA 跨环境成功率。

FailGen 在 PickCube、StackCube 上执行 grasp、trans_x 两类注入, 种子 7、8, 共 8 次, 终局成功 4 条、失败 4 条。没有把注入事件直接当作失败。当前上游输出以多视角拼接帧为主, 完整时序 HDF5 保存未启用, 不能将这 8 次视为完整训练集。

AHA 的 57 条 REFLECT 记录与图像可读, 但未获得可直接评测的最终 critic 权重; FailGen 运行通过不等于 AHA 模型复现。

证据: WCM 范围及原始数值入口

证据: 失败注入、实际结果及环境兼容记录

证据: 三任务环境验证

10 未完成定量复现的工作与原因

2026 年 9 月 5 日重新核查作者仓库、论文入口及发布权重。以下区分资源缺失与完整运行条件不足；未找到资源不等于证明其永久不存在。I-FailSense 的授权和传输问题已经解决，定量结果单列于前文。

工作	状态	未完成原因及研究位置
ActiveVLA	L0	审计副本仅说明与素材，代码、权重、评测仍标为待发布。用于任务区域定位、视角与尺度动作设计，不填写模型分数。
ADV / VeGAS	L0	ADV 尚未定位到官方可执行入口；VeGAS 作者仓库已找到，但仍为 Code Coming Soon。用于候选与验证器排序参考，不以自写替代实现冒充复现。
AHA	L1	数据与源码可检查，最终可直接评测的 critic 权重未具备。失败解释结构可借鉴，性能未知。
VAP-TAMP	L1	完整运行涉及 ROS2、OmniGibson、在线 API 与实体机器人配置；当前单服务器条件不齐。用于前置条件、效果验证和场景图接口参考。
Thea	L1	预览代码需要自备策略、episode 与 evaluator。工具协议和 exit code 可审计，未复现论文级仿真成功率。
Self-Harness / Zetta	L1	Zetta 具备 campaign 框架，但原实验需特定策略、环境及真实 coding 模型后端；当前 OFT 不等同于其原协议。用于代码迭代与回归门控参考。

10.1 引用与对照边界

以上工作可以进入相关工作和系统设计依据，不能进入“已复现数值”主表。环境安装、单元测试、代码导入或少量前向均不能升级为论文性能复现。

本项目的程序式决策、预算运行时、失败案例包及拒绝式回归检查属于自建基础设施，不是对 Self-Harness、Zetta 或 Thea 整套系统的替代复现，也不能报告这些方法的“提升幅度”。

公开数据、发布权重和可重现脚本具备时，仍须按同任务、同输入权限、同预算冻结协议；引用相近思想不等于把若干模型拼接后称作新方法。

证据：作者资源链接、审计提交及运行条件

11 综合分析与统一对照边界

11.1 从当前实测得到的结论

- 标准任务的策略成功率不能充分暴露验证器价值。必须同时测量错误是否被及时发现、查询是否改变判断、恢复是否有效，以及额外成本。
- 失败分数的排序能力与报警可靠性不同。WidowX 的 MLP 累计 AUROC 较高，仍可出现高误报；DROID 的固定配置跨任务排序较弱。OOD 校准必须报告实际 FPR/TPR，不能只写 α 。
- 历史表征、白盒特征和主动证据的输入权限不同。WCM、SAFE、外部视觉 critic 的比较需要明确可见信息及成本，不能直接跨数据集排优劣。
- 现有实验支持“跨任务风险判断与证据充分性值得建模”的问题定位，但尚未证明主动查询一定改善结果，也未证明任何自建新方法优于基线。

11.2 已实现的统一协议与采集接续

固定协议区分训练、校准、开发和默认密封测试；同初态根的扰动、证据及恢复分支不跨集合。真值与决策上下文分离，缺失监督使用有效性掩码，不将 null 填成负类。候选程序只能在受限语法中表达决策，预算和工具权限由固定运行时执行。

初批验收 21 条、13 根、166 个决策点；接续新增 12 条、6 根、168 点，合计 33 条、19 根。新批 clean 为 6 成功；动作噪声为 5 成功、1 超时失败。40 项自动测试通过，完整记录复跑跳过，无覆盖。以上是工程验收，不是统计充分的模型主表。

DROID 登记为外部诊断资源，15 条异常隔离，拒绝进入主训练/校准；已用于基线的 780 条不标记为未触碰测试。视频时序对齐未核实，不生成虚构的主动视角或恢复反事实。

11.3 尚未完成的研究模块

630 条正式训练采集计划已冻结，尚未全量执行。多层失败语义、最早有效干预与可恢复性标签仍不齐；主环境多模态 critic 训练校准、真实 ROI/强模型工具、coding 模型后端及完整在线恢复闭环未完成。

论文统一主表必须固定 critic、输入、任务根与预算，再比较无查询、固定查询、路由和恢复。当前结果不能提前写成新模型性能、完整自进化收益或顶会可接受性的保证。证据：协议、采集接续和有效监督审计

12 实验溯源与复查入口

12.1 代码与运行环境

主计算设备为单张 RTX 5090 32 GB。策略、SAFE、WCM、ManiSkill/FailGen 使用隔离环境；不同任务的依赖和计时条件分别记录，不能假设软件栈完全相同。

上游源码	实验审计提交（缩写）
OpenVLA-OFT	e4287e94541f
AVA-VLA	69ae5dfb90f4
SAFE	b6036abe07b2
WCM	d028ebbf2cf
LIBERO-original	8f1084e3132a
LIBERO-plus	4976dc30028e
ManiSkill-FailGen	fa697a57219c
I-FailSense	0c71f564cece

完整提交、逐运行配置、精确 split 和结果文件属于复现证据。报告数字保留必要小数位，原始精度留在机器可读结果中；不同随机划分的样本标准差不是任务级置信区间。

12.2 仓库中可直接复查的内容

- docs/reproduction：逐工作结果、配置说明、失败原因、数据状态。
- results/20260905：策略配对、SAFE 两域 LSTM/MLP、12 组距离型与 6 组 RND、标签敏感性分析、I-FailSense 完整模型及组件逐样本证据。
- results/WCM：WCM 汇总与逐 episode 曲线记录。
- docs/protocol：固定协议、私有标签边界、采集验收、续跑检查和代码反馈案例。

12.3 大文件与完整复现实验

原始数据、视频、SAFE 最终权重、训练特征库及逐轨迹预测数组保留在服务器数据盘，不上传 GitHub。以下目录均位于 /root/autodl-tmp/ 下：基线 experiments/baselines-20260905；WCM experiments/wcm/full-val；新管线 experiments/bav-pipeline-v1 和 experiments/bav-train-multitask-v1。

训练与评测入口位于仓库 scripts；分项文档记录完整命令与路径。报告源文件与 PDF 一并版本管理；本轮新增实验使用独立版本目录，不覆盖既有结果。