

Baseline Report

1 Baseline 五列总表

表 1: 既有实验总表：论文报告与本项目实际运行分别列示。

dataset	model	harness	reported performance (in paper)	our reproduced performance
A. 策略闭环：有限规模				
LIBERO Spatial	OpenVLA-OFT	H1: 作者策略循环；双相机 + 本体；10 任务 × 5 初态；无外加验证/恢复。	SR 97.6%；Spatial 专用策略。[1]	SR 100.00% (50/50)；每任务 5 次，不是论文 50 次。
LIBERO Spatial	AVA-VLA	H1: 作者策略循环；双相机 + 本体；10 任务 × 5 初态；无外加验证/恢复。	SR 97.4%；四套件联合策略。[2]	SR 96.00% (48/50)；每任务 5 次，不是论文 50 次。
B. OOD：旧实现诊断，不进入主结果				
LIBERO-Plus Spatial 子集	OpenVLA-OFT	H2: 七轴各 10 次；两策略同名单；保留上游提示词混杂。	全套件 SR 69.6%；仅作背景参照，非本批 Spatial 子集。[3]	SR 82.86% (58/70)；诊断值，不作论文优劣比较。
LIBERO-Plus Spatial 子集	AVA-VLA	H2: 七轴各 10 次；两策略同名单；保留上游提示词混杂。	NR: AVA 论文未报告本批 Plus 协议。[2]	SR 78.57% (55/70)；诊断值，不作论文优劣比较。
C. 失败检测：固定配置，未见任务				
SAFE rollout OpenVLA / WidowX	SAFE-LSTM	H3: 白盒特征；3 种子；1,000 epoch；按任务划分；仅评分/校准，不干预。	NR: 原论文未列出 WidowX 域数值。[4]	未见任务 AUROC 62.78 ± 0.99；AUPRC 73.98 ± 2.30。
SAFE rollout OpenVLA / WidowX	SAFE-MLP	H3: 白盒特征；3 种子；1,000 epoch；按任务划分；仅评分/校准，不干预。	NR: 原论文未列出 WidowX 域数值。[4]	未见任务 AUROC 81.85 ± 3.67；AUPRC 87.34 ± 3.84。
SAFE rollout OpenVLA / WidowX	Cosine kNN	H4: 同 H3 划分；固定 k=5；训练轨迹建库，无梯度训练。	NR: 原论文未列出 WidowX 域数值。[4]	未见任务 AUROC 63.64 ± 7.51；AUPRC 67.61 ± 7.32。
SAFE rollout OpenVLA / WidowX	Euclidean kNN	H4: 同 H3 划分；固定 k=5；训练轨迹建库，无梯度训练。	NR: 原论文未列出 WidowX 域数值。[4]	未见任务 AUROC 53.67 ± 6.92；AUPRC 64.45 ± 7.30。
SAFE rollout OpenVLA / WidowX	RND	H5: 同划分；3 种子 × 200 epoch；小尾批合并；仅检测，无恢复。	NR: 原论文未列出 WidowX 域数值。[4]	未见任务 AUROC 49.41 ± 4.01；AUPRC 59.56 ± 4.96。
SAFE rollout Pi0-FAST / DROID	SAFE-LSTM	H3: 白盒特征；3 种子；1,000 epoch；按任务划分；仅评分/校准，不干预。	未见任务 AUROC 58.70 ± 4.37；Real Franka 列，论文调优配置。[4]	未见任务 AUROC 53.58 ± 2.08；AUPRC 53.93 ± 4.75。

续下页

表 1 (续)

dataset	model	harness	reported performance (in paper)	our reproduced performance
SAFE rollout Pi0-FAST / DROID	SAFE-MLP	H3: 白盒特征; 3 种子; 1,000 epoch; 按任务划分; 仅评分/校准, 不干预。	未见任务 AUROC 64.16 ± 5.88; Real Franka 列, 论 文调优配置。[4]	未见任务 AUROC 53.53 ± 4.45; AUPRC 61.34 ± 3.01。
SAFE rollout Pi0-FAST / DROID	Cosine kNN	H4: 同 H3 划分; 固定 k=5; 训练轨迹建库, 无梯 度训练。	未见任务 AUROC 59.51 ± 5.76; Real Franka 列, 论 文调优配置。[4]	未见任务 AUROC 49.43 ± 3.57; AUPRC 49.19 ± 2.54。
SAFE rollout Pi0-FAST / DROID	Euclidean kNN	H4: 同 H3 划分; 固定 k=5; 训练轨迹建库, 无梯 度训练。	未见任务 AUROC 60.27 ± 4.79; Real Franka 列, 论 文调优配置。[4]	未见任务 AUROC 53.74 ± 3.97; AUPRC 52.60 ± 1.51。
SAFE rollout Pi0-FAST / DROID	RND	H5: 同划分; 3 种子 ×200 epoch; 小尾批合并; 仅检 测, 无恢复。	未见任务 AUROC 45.83 ± 5.10; Real Franka 列, 论 文调优配置。[4]	未见任务 AUROC 48.87 ± 1.96; AUPRC 49.38 ± 0.98。
D. 图像/时序拼图判断: 作者派生测试集				
SMF-CALVIN 公开 1p 数据	I-FailSense 完整模型	H6: 单视角时序拼图 + 文 本; 203 样本; 固定发布权 重; 离线投票/解码。	1p accuracy 90.64%; Table I. [5]	Accuracy 90.64% (184/203); 与论文保留位一 致。
SMF-CALVIN 公开 1p 数据	I-FailSense LoRA/VLM 组件	H6: 单视角时序拼图 + 文 本; 203 样本; 固定发布权 重; 离线投票/解码。	1p accuracy 85.71%; Table I. [5]	Accuracy 85.71% (174/203); 与论文保留位一 致。
E. 世界模型: 公开小型验证协议				
WCM pick-place val	WCM	H7: 固定公开权重; 18 episode / 1,617 窗口; 值与 下一状态预测。	NR: 未定位同一 quick-val 的误差报告; 论文 RL 成功 率不可替代。[6]	Value RMSE 0.380342; MAE 0.196550; Pearson 0.720664; next-state MSE 0.007358。
F. 数据生成与环境检查: 不是模型性能				
ManiSkill3 三任务	官方演示 动作回放	H8: PickCube、 StackCube、 PegInsertionSide 各 3 条; 执行动作, 不逐帧写真值。	N/A: 工程回放, 不是学习 策略论文指标。	9/9 回放成功; 只说明演示可 执行。
ManiSkill3 两任务	FailGen 失败注入器	H9: grasp / trans_x; seed 7/8; 按环境终局判定, 不 把注入直接当失败。	N/A: 不是 AHA 检测准确 率。	8/8 链路完成; 4 成功、4 失 败。

SR / accuracy 用百分数; AUROC / AUPRC 用 0-100 尺度。本次 SAFE 为三种子均值 ± 样本标准差, 采用每任务最短轨迹窗口内最大风险分数; 不代表实际检测提前量。

NR: 论文未给出对应域/协议值; N/A: 非模型性能。两列并排不等于同协议比较; 样本量、调优范围和 Plus 旧提示词混杂已在表内标明。

2 Harness 含义与执行流程

Model 指执行预测的模型；harness 指组织输入、模型调用、动作执行、结果判定与记录的外围流程。H1-H9 是本报告的流程编号，不是九种论文方法，也不是九套已完成的主动验证系统。训练轮数与种子属于实验配置，不属于决策机制。

H1：标准策略执行循环

适用与输入：OpenVLA-OFT / AVA-VLA，标准 LIBERO Spatial。输入为任务指令、双相机图像和机器人本体状态。

执行流程：读取观测 → 策略生成 8 步动作块 → 环境执行 → 获取新观测 → 重复，成功或达到步数上限时结束。本批包含 10 步稳定等待，任务执行上限为 220 步。

输出与边界：输出逐轨迹成功与否及执行记录。AVA 使用其发布配置的历史动作特征和注意力机制，属于模型内部能力；外层没有附加 critic、主动查询或独立恢复模块。策略自行纠偏不等于外加恢复系统。

研究位置：无附加验证的执行策略对照。两种发布权重训练范围不同，当前差异不能全部归因于注意力机制。

H2：扰动环境中的策略执行

适用与输入：OpenVLA-OFT / AVA-VLA，LIBERO-Plus Spatial 子集。两策略使用同一评测名单，输入权限与 H1 同类。

执行流程：选定扰动任务与初态 → 运行标准策略循环 → 环境判定结果 → 按扰动维度汇总。相机、布局、光照、语言、纹理、初态和传感器噪声七轴各 10 次。

输出与边界：输出扰动下成功率；没有增加异常检测、主动观察或恢复决策。旧运行部分指令混入扰动名称，成绩仅作实现诊断。

研究位置：H1 的扰动评测版本，不是另一种主动 harness。正式 OOD 对照使用消除非目标提示词混杂的冻结协议；语言扰动本身与意外后缀分开处理。

H3：学习型被动失败监测

适用与输入：SAFE-MLP / SAFE-LSTM；分别使用 WidowX 与 DROID 已记录的 VLA 内部特征及轨迹标签，需要白盒特征访问。

执行流程：按任务划分数据 → 固定配置训练检测器 → 读取测试轨迹特征并输出逐时刻风险 → 汇总评分 → 使用独立校准数据确定报警阈值。MLP 映射特征，LSTM 利用时序信息。

输出与边界：三种子、每种子 1,000 epoch。仅离线评分与校准，不改变机器人动作；总表采用统一窗口内最大风险的 AUROC/AUPRC，不表示检测提前量或恢复收益。OOD 下校准目标不自动成为误报保证。

研究位置：已有证据上的被动风险检测对照；不判断缺少哪类证据，也不主动调用外部视觉工具。

H4: 基于特征检索的被动监测

适用与输入: SAFE 官方 Cosine / Euclidean kNN; 数据、任务划分与 H3 相同, 两域分别建立特征库。

执行流程: 用训练轨迹有效时间步建立成功库和失败库 → 查询特征分别检索 $k=5$ 近邻 → 以到成功库的距离减去到失败库的距离构造风险 → 评分与阈值校准。

输出与边界: 两者仅距离度量不同, 无梯度训练; 特征库显式保存并重新加载验证。检索仍有存储与计算成本, 不能把无需训练写成零成本。测试数据不参与建库。

研究位置: 简单、可解释的风险对照。未见任务可能只是远离训练特征, 并非执行失败; 该机制不获取新的视觉证据。

H5: 预测误差式被动监测

适用与输入: SAFE 官方 RND; 使用与 H3 相同的策略特征、轨迹筛选和任务划分。

执行流程: 特征进入固定随机目标网络与可训练预测网络 → 按官方损失训练 → 根据预测误差构造风险 → 逐轨迹评分与校准。当前配置中成功和失败均参与训练, 不是仅用成功数据的普通异常检测。

输出与边界: 三种子、每种子 200 epoch; 小尾批并入前批以避免原损失的数值异常, 不丢弃轨迹。当前固定配置的检测排序较弱, 不代表完整调参后的能力上限。

研究位置: 另一类被动风险信号。陌生程度不等于失败程度; 没有主动查询、动作干预或恢复执行。

H6: 视觉语义失败判断

适用与输入: I-FailSense; 单视角时序拼图与任务文本。固定公开底座、LoRA 和分类器权重, 在作者 validation 派生的同一批 203 样本上评测, 不重新训练。

执行流程: 完整模型: 图文输入 → VLM 特征与解码判断 → 三路分类器与 VLM 加权投票 → 成功/失败。组件对照: 相同图文输入 → LoRA/VLM 单 token 解码 → 按作者规则映射标签, 不调用完整分类器组合。

输出与边界: 输出逐样本判断与 accuracy; 完整模型票数比例不是校准概率。该批数据不是自行冻结的全新 OOD 测试集, 离线识别也不等于在线恢复。

研究位置: 任务条件视觉验证工具的参考。输入证据预先固定, 没有主动换视角、证据预算分配或恢复闭环。

H7: 固定历史窗口预测

适用与输入: WCM 官方 pick-place quick benchmark 与公开检查点; 18 个 episode、1,617 个历史时序窗口。

执行流程: 按官方验证划分构造窗口 → 固定 WCM 前向预测价值与下一状态 → 与数据目标比较 → 汇总预测误差和相关性。

输出与边界: 报告价值 RMSE、MAE、Pearson 和下一状态 MSE。没有执行完整 VLA-RL 控制闭环; 公开 quick benchmark 只含成功轨迹, 不能单独证明失败检测或恢复能力。

研究位置: 部分可观测条件下的历史表征参考。固定窗口不会决定何时检索历史、选择哪些证据或何时停止查询。

H8: 官方演示动作回放

适用与输入: ManiSkill3 的 PickCube、StackCube、PegInsertionSide, 各 3 条官方演示; 输入为演示初态和动作序列。

执行流程: 加载演示与初态 → 在仿真中执行记录动作 → 读取环境终局判定 → 汇总回放结果。执行动作, 不逐帧强制写入演示状态。

输出与边界: 9/9 回放成功。没有学习模型根据图像作决策, 因此不是策略成功率基线, 只证明选定演示、动作接口和环境执行链路可用。

研究位置: 第二环境的数据采集与执行接口验收, 不与新模型的性能直接排名。

H9: 程序化扰动与结果标注

适用与输入: ManiSkill-FailGen; PickCube / StackCube, grasp / trans_x 两类扰动, 种子 7/8, 共 8 次运行。

执行流程: 选定任务与扰动配置 → 注入抓取或平移扰动并继续执行 → 读取环境实际结果 → 保存生成图像及成功/失败记录。扰动注入本身不作为失败标签。

输出与边界: 8/8 链路完成, 其中 4 成功、4 失败。当前上游入口主要保存多视角拼接帧, 未构成含完整时序、动作、证据成本和恢复分支的正式训练数据集; 不是 AHA critic 的准确率。

研究位置: 可控失败案例生成工具。用于后续数据管线扩展, 不是失败检测模型或已经完成的恢复系统。

3 有提升空间的数据集

以下为特定版本与协议下的性能证据，不是全社区最新排名；剩余失败也不一定都可由主动观察解决。标准 LIBERO 仅保留为干净控制项，不作为主要提升空间。

3.1 LIBERO-Plus: 扰动下的主动验证与恢复

作者报告 OFT 全套件 SR 69.6%，其中相机扰动 56.4%、初态扰动 31.9%；mix-SFT 整体 79.5%，仍有提升空间。[3] 本研究用于视觉/初态等分布变化下的证据获取与失败恢复。代码和资产已有；现有 70 次结果含提示词混杂，仅作诊断，正式比较须使用冻结的无混杂协议。

3.2 MIKASA-Robo: 历史证据与部分可观测判断

MemoryVLA 论文五任务协议中，OFT SR 28.4%、MemoryVLA 41.2%。[7] 该协议包括 ShellGameTouch、InterceptMedium、RememberColor3/5/9，适合检验历史检索和证据不足判断。环境与数据公开，但本项目尚未接入或复现；不能将旧五任务成绩套到当前 90 任务版本。[8] 模型只能查询真实保存的历史，不获取未记录的过去或状态真值。

3.3 SAFE Pi0-FAST / DROID: 真实跨任务失败检测

论文 Real Franka 列中 MLP 的未见任务 AUROC 为 64.16，本次固定配置为 53.53；该差距含调优协议差异，不能直接视作新方法可获得的增益。[4] 已有 1,464 条原始 rollout、780 条既用筛选数据，可用于真实域离线验证。它不是 DROID 全集，也不提供交互式新视角或真实恢复反事实；标签异常与既往数据使用须保留记录。

3.4 RoboCasa365: 长时序家庭操作扩展

论文 Table 2 的 GR00T N1.5 在预训练 + 目标全数据微调设置下，atomic SR 68.5%、composite-seen 40.6%、composite-unseen 42.1%。[9] 复合任务仍有明显空间，适合环境反馈与阶段性恢复。该数据集作为扩展项，尚未完成本项目基线；控制适配与长时序采集成本较高，不与旧版 RoboCasa 成绩混用。