

Baseline Report

1 Baseline 五列总表

表 1: 既有实验总表：论文报告与本项目实际运行分别列示。

dataset	model	harness	reported performance (in paper)	our reproduced performance
A. 策略闭环：有限规模				
LIBERO Spatial	OpenVLA-OFT	H1: 作者策略循环；双相机 + 本体；10 任务 × 5 初态；无外加验证/恢复。	SR 97.6%；Spatial 专用策略。[1]	SR 100.00% (50/50)；每任务 5 次，不是论文 50 次。
LIBERO Spatial	AVA-VLA	H1: 作者策略循环；双相机 + 本体；10 任务 × 5 初态；无外加验证/恢复。	SR 97.4%；四套件联合策略。[2]	SR 96.00% (48/50)；每任务 5 次，不是论文 50 次。
B. OOD：旧实现诊断，不进入主结果				
LIBERO-Plus Spatial 子集	OpenVLA-OFT	H2: 七轴各 10 次；两策略同名单；保留上游提示词混杂。	全套件 SR 69.6%；仅作背景参照，非本批 Spatial 子集。[3]	SR 82.86% (58/70)；诊断值，不作论文优劣比较。
LIBERO-Plus Spatial 子集	AVA-VLA	H2: 七轴各 10 次；两策略同名单；保留上游提示词混杂。	NR: AVA 论文未报告本批 Plus 协议。[2]	SR 78.57% (55/70)；诊断值，不作论文优劣比较。
C. 失败检测：固定配置，未见任务				
SAFE rollout OpenVLA / WidowX	SAFE-LSTM	H3: 白盒特征；3 种子；1,000 epoch；按任务划分；仅评分/校准，不干预。	NR: 原论文未列出 WidowX 域数值。[4]	未见任务 AUROC 62.78 ± 0.99；AUPRC 73.98 ± 2.30。
SAFE rollout OpenVLA / WidowX	SAFE-MLP	H3: 白盒特征；3 种子；1,000 epoch；按任务划分；仅评分/校准，不干预。	NR: 原论文未列出 WidowX 域数值。[4]	未见任务 AUROC 81.85 ± 3.67；AUPRC 87.34 ± 3.84。
SAFE rollout OpenVLA / WidowX	Cosine kNN	H4: 同 H3 划分；固定 k=5；训练轨迹建库，无梯度训练。	NR: 原论文未列出 WidowX 域数值。[4]	未见任务 AUROC 63.64 ± 7.51；AUPRC 67.61 ± 7.32。
SAFE rollout OpenVLA / WidowX	Euclidean kNN	H4: 同 H3 划分；固定 k=5；训练轨迹建库，无梯度训练。	NR: 原论文未列出 WidowX 域数值。[4]	未见任务 AUROC 53.67 ± 6.92；AUPRC 64.45 ± 7.30。
SAFE rollout OpenVLA / WidowX	RND	H5: 同划分；3 种子 × 200 epoch；小尾批合并；仅检测，无恢复。	NR: 原论文未列出 WidowX 域数值。[4]	未见任务 AUROC 49.41 ± 4.01；AUPRC 59.56 ± 4.96。
SAFE rollout Pi0-FAST / DROID	SAFE-LSTM	H3: 白盒特征；3 种子；1,000 epoch；按任务划分；仅评分/校准，不干预。	未见任务 AUROC 58.70 ± 4.37；Real Franka 列，论文调优配置。[4]	未见任务 AUROC 53.58 ± 2.08；AUPRC 53.93 ± 4.75。

续下页

表 1 (续)

dataset	model	harness	reported performance (in paper)	our reproduced performance
SAFE rollout Pi0-FAST / DROID	SAFE-MLP	H3: 白盒特征; 3 种子; 1,000 epoch; 按任务划分; 仅评分/校准, 不干预。	未见任务 AUROC 64.16 ± 5.88 ; Real Franka 列, 论文调优配置。[4]	未见任务 AUROC 53.53 ± 4.45 ; AUPRC 61.34 ± 3.01 。
SAFE rollout Pi0-FAST / DROID	Cosine kNN	H4: 同 H3 划分; 固定 k=5; 训练轨迹建库, 无梯度训练。	未见任务 AUROC 59.51 ± 5.76 ; Real Franka 列, 论文调优配置。[4]	未见任务 AUROC 49.43 ± 3.57 ; AUPRC 49.19 ± 2.54 。
SAFE rollout Pi0-FAST / DROID	Euclidean kNN	H4: 同 H3 划分; 固定 k=5; 训练轨迹建库, 无梯度训练。	未见任务 AUROC 60.27 ± 4.79 ; Real Franka 列, 论文调优配置。[4]	未见任务 AUROC 53.74 ± 3.97 ; AUPRC 52.60 ± 1.51 。
SAFE rollout Pi0-FAST / DROID	RND	H5: 同划分; 3 种子 $\times$ 200 epoch; 小尾批合并; 仅检测, 无恢复。	未见任务 AUROC 45.83 ± 5.10 ; Real Franka 列, 论文调优配置。[4]	未见任务 AUROC 48.87 ± 1.96 ; AUPRC 49.38 ± 0.98 。
D. 图像/时序拼图判断: 作者派生测试集				
SMF-CALVIN 公开 1p 数据	I-FailSense 完整模型	H6: 单视角时序拼图 + 文本; 203 样本; 固定发布权重; 离线投票/解码。	1p accuracy 90.64%; Table I. [5]	Accuracy 90.64% (184/203); 与论文保留位一致。
SMF-CALVIN 公开 1p 数据	I-FailSense LoRA/VLM 组件	H6: 单视角时序拼图 + 文本; 203 样本; 固定发布权重; 离线投票/解码。	1p accuracy 85.71%; Table I. [5]	Accuracy 85.71% (174/203); 与论文保留位一致。
E. 世界模型: 公开小型验证协议				
WCM pick-place val	WCM	H7: 固定公开权重; 18 episode / 1,617 窗口; 值与 下一状态预测。	NR: 未定位同一 quick-val 的误差报告; 论文 RL 成功率不可替代。[6]	Value RMSE 0.380342; MAE 0.196550; Pearson 0.720664; next-state MSE 0.007358。
F. 数据生成与环境检查: 不是模型性能				
ManiSkill3 三任务	官方演示 动作回放	H8: PickCube、 StackCube、 PegInsertionSide 各 3 条; 执行动作, 不逐帧写真值。	N/A: 工程回放, 不是学习 策略论文指标。	9/9 回放成功; 只说明演示可 执行。
ManiSkill3 两任务	FailGen 失败注入器	H9: grasp / trans_x; seed 7/8; 按环境终局判定, 不 把注入直接当失败。	N/A: 不是 AHA 检测准确 率。	8/8 链路完成; 4 成功、4 失 败。

SR / accuracy 用百分数; AUROC / AUPRC 用 0-100 尺度。本次 SAFE 为三种子均值 $\pm$ 样本标准差, 采用每任务最短轨迹窗口内最大风险分数; 不代表实际检测提前量。

NR: 论文未给出对应域/协议值; N/A: 非模型性能。两列并排不等于同协议比较; 样本量、调优范围和 Plus 旧提示词混杂已在表内标明。

2 有提升空间的数据集

以下为特定版本与协议下的性能证据，不是全社区最新排名；剩余失败也不一定都可由主动观察解决。标准 LIBERO 仅保留为干净控制项，不作为主要提升空间。

2.1 LIBERO-Plus: 扰动下的主动验证与恢复

作者报告 OFT 全套件 SR 69.6%，其中相机扰动 56.4%、初态扰动 31.9%；mix-SFT 整体 79.5%，仍有提升空间。[3] 本研究用于视觉/初态等分布变化下的证据获取与失败恢复。代码和资产已有；现有 70 次结果含提示词混杂，仅作诊断，正式比较须使用冻结的无混杂协议。

2.2 MIKASA-Robo: 历史证据与部分可观测判断

MemoryVLA 论文五任务协议中，OFT SR 28.4%、MemoryVLA 41.2%。[7] 该协议包括 ShellGameTouch、InterceptMedium、RememberColor3/5/9，适合检验历史检索和证据不足判断。环境与数据公开，但本项目尚未接入或复现；不能将旧五任务成绩套到当前 90 任务版本。[8] 模型只能查询真实保存的历史，不获取未记录的过去或状态真值。

2.3 SAFE Pi0-FAST / DROID: 真实跨任务失败检测

论文 Real Franka 列中 MLP 的未见任务 AUROC 为 64.16，本次固定配置为 53.53；该差距含调优协议差异，不能直接视作新方法可获得的增益。[4] 已有 1,464 条原始 rollout、780 条既用筛选数据，可用于真实域离线验证。它不是 DROID 全集，也不提供交互式新视角或真实恢复反事实；标签异常与既往数据使用须保留记录。

2.4 RoboCasa365: 长时序家庭操作扩展

论文 Table 2 的 GR00T N1.5 在预训练 + 目标全数据微调设置下，atomic SR 68.5%、composite-seen 40.6%、composite-unseen 42.1%。[9] 复合任务仍有明显空间，适合环境反馈与阶段性恢复。该数据集作为扩展项，尚未完成本项目基线；控制适配与长时序采集成本较高，不与旧版 RoboCasa 成绩混用。