

# 机器人操作 Agent 长程时序能力测试报告

# 1 测试范围与结果

测试面向机器人操作的 Agent，关注多步执行中的目标身份、子目标进展、历史状态、失败恢复和完成判断。全部使用真实仿真执行，不以工具模拟回复或安装检查代替性能。记录覆盖 2026 年 9 月 15–16 日。

**总体结论：**现有部署能够组织操作，但“物理任务成功”“验证器认识到成功”和“正确停止”经常脱节。本轮已经定位具体失败链条，尚未证明它们都是长程记忆退化，也没有证明任何适配 Agent 带来稳定的总体提升。

| 系统               | 场景与样本                    | 实际保留的机制                      | 最终成功 | 曾经成功 |
|------------------|--------------------------|------------------------------|------|------|
| Fixed Pi0.5      | A: LIBERO-10, 10 条       | 无上层 Agent, 固定策略执行            | 7/10 | 9/10 |
| EmbodiedSkills   | A: 同上, 10 条              | 子目标计划、阶段约束、验证与恢复             | 4/10 | 5/10 |
| Thea port        | A: 同上, 10 条              | 原生 Harness、任务笔记、上下文管理与独立验证   | 6/10 | 6/10 |
| RPent            | B: LIBERO-10, 10 条       | 公开记忆、RGB-D 定位、VLA 与直接控制工具    | 2/10 | 3/10 |
| Fixed Pi0.5      | C: 任务 5, 3 条             | 冻结策略; Zetta 的配对控制组           | 2/3  | 2/3  |
| Zetta 候选         | C: 同上, 3 条               | 失败诊断、冻结 critic、Role1 复核与恢复执行 | 2/3  | 2/3  |
| CaP-Agent0 单模型适配 | D: LIBERO-PRO 中任务 0, 1 条 | 九候选代码生成、综合、技能调用、视觉反馈与重写      | 0/1  | 0/1  |

## 表格如何比较

A 组为同一 Pi0.5、相同十任务与初态的比较：双路 RGB、最长 32 步动作段、520 步上限。B 组增加高清 RGB-D、直接控制和记忆，VLA 动作段为 5 步。C 组为同一任务的三个留出初态，5 步动作段、520 步上限；候选与控制组初态及首次介入前动作一致。D 组保留原生关节控制、IK 和抓取模型，原生预算 8000 步，其中十步为稳定过程。

**不同协议之间不能直接排名。**主表共 47 条有效轨迹；Zetta 另采集 18 条固定策略开发轨迹，不混入留出成绩。最终成功指停止时真值，曾经成功指任一步曾满足真值；任务真值均只用于评分，不提供给 Agent 或用于自动成功停止。

## 2 状态记忆、子目标与完成判断

### Thea port: 历史事件没有转化为可靠的持续状态

**失败事实。**任务 3 要求把碗放入抽屉并关上。动作回放确认：第 138 步起碗已入抽屉，第 208 步抽屉关闭，完整目标在 208–245 步持续成立；但 Agent 在第 245 步放弃，理由涉及看不到碗、无法辨认抽屉，甚至怀疑场景重置。Agent 没有环境重置权限。

**原因与时序关联。**物体被遮挡之后，当前画面不能直接显示先前事件；当前部署未可靠保留“已放入且随后关闭”的状态及其证据。它把不可见与状态失效混淆。这是跨时刻状态维护问题；但部署缺少完整 Scene Graph，不能把结果直接归因于 Thea 完整架构。

**另一个失败。**任务 2 在第 225 步宣布完成。逐步回放显示炉灶从第 86 步起已开启，但摩卡壶进入指定区域的条件始终未成立。这里是复合目标只验证了一部分。全组唯一一次 complete 为误报，而六条物理成功轨迹均没有被正确 complete 确认。

**部署干扰。**Agent 还把“抬臂、获得宽视角”等观察指令交给固定 VLA，但本部署没有独立验收过的视角移动技能。因此失败同时受工具能力限制影响，不是单纯增加记忆就能解释。

### EmbodiedSkills: 目标身份与验证循环阻塞子目标推进

**失败事实。**任务 0 的八段动作指令一直停留在抓取汤罐，未越过第一阶段。第 96 步可见夹持罐体，第 128 步罐体移到篮子上方，七次验证仍未确认抓取子目标。十条轨迹均在 256 个物理步后耗尽 160 次模型调用。

**原因证据。**固定第 96 步图像，用原上下文、删除历史状态、增加历史图像三种输入各测试三次，命名目标的抓持判断均未肯定；改问“不猜商品名，是否持有任意物体”，三次均肯定。输入图像哈希核对无旧图传输问题。

**归因边界。**证据更支持语言目标与视觉实体对应困难，导致重复验证和阶段停滞。添加历史图像未修复该检查点，不支持直接宣称“缺少长期记忆就是主因”。中性提问改变了问题，不能作为同一指标的准确率提升。

### 固定策略：达到目标后缺少停止与状态保护

A 组有 9/10 曾经成功，但最终仅 7/10；任务 5、6 在达到目标后再次失效。无 Agent 控制组没有完成识别和主动停止机制。该现象说明必须分别测量达到、维持和确认目标，不能只看最终一个成功率。原生谓词也不必然包含松爪与长期稳定性要求。

### 3 证据获取、恢复与代码决策

#### RPent：多轮获取证据没有保证收敛

**失败事实。**十条轨迹中六条耗尽费用预算，三条耗尽物理预算，一条遇到输出长度上限。任务 5 累计决策输入约 177 万 tokens，反复读取案例、分割、反投影与移动；在第 332 步声称成功谓词尚未触发，但该真值并未提供给它。

**原因与边界。**日志支持未知状态被当作负面证据、冲突图像描述下继续反复定位，以及低收益工具循环消耗预算。公开记忆还存在任务文件命名不匹配和跨布局案例迁移，属于部署与检索干扰。没有消融证据证明上下文长度本身导致失败。任务 5 仅在第 327–328 步短暂满足真值，第 329 步已失效；不能声称它稳定完成后被 Agent 重启破坏。

#### Zetta：critic 把完成后静止误判为需要恢复

**失败事实。**用开发失败轨迹生成并冻结候选后，在三个留出初态进行配对测试。候选实际触发九次恢复，其中六次发生在已成功状态，五次之前连续十步也已成功；唯一失败初态三次恢复后仍未成功。控制与候选均为 2/3，无救回、无退化，候选未晋升。

**原因与时序关联。**本候选把动作停滞、末端位置和夹爪开度组合成失败条件，不能可靠区分“仍握物”“已释放”和“完成后保持”。恢复仍调用同一 VLA 与完整任务指令，没有新增观察或有效子目标切换。首次介入后的动作确实改变，但未产生收益；不是完全未执行的空操作。

**归因边界。**这是单个候选的小规模在线测试，不是完整演化训练。早期诊断还把未执行的 IK 工具当作失败原因，经控制来源澄清后重新生成；通过引用与格式校验不等于因果解释正确。

#### CaP-Agent0：代码无异常不等于后置条件成立

**失败事实。**任务 0 共执行十段代码、九次重写，记录 7990 个实际操作步；前九段无运行异常，第十段达到环境上限。第一段打印两个物体均已入篮，但后续图像显示篮子仍空，逐步真值始终未成功。后续持续重新定位、抓取和放置，未满足组合目标。

**原因与时序关联。**代码的局部完成声明没有验证真实物体关系；多候选分割、抓取分数和到达位姿不足以证明指定物体已入篮并保持。图像还显示物品被带倒、篮子位移。原生 Agent 选择继续重写而非 FINISH，因此这里不是最终完成误报，而是局部后置条件薄弱、状态改变后重试无法稳定推进。尚不能分离感知、接触控制和规划各自的贡献。

## 4 结论与可复核记录

### 与长程时序能力直接相关的研究问题

本轮最明确的研究对象不是笼统的“更长上下文”，而是下列三个状态转换：

1. **从观察到持久状态**：对象身份是否一致；已完成事件在遮挡后是否仍成立；什么时候必须重新观察。
2. **从停滞到恢复**：区分进行中、证据不足、动作失败与已完成；避免仅凭夹爪或静止信号启动恢复。
3. **从执行返回到任务完成**：验证多个子目标的联合后置条件，保护已完成部分，并依据证据决定继续、恢复或停止。

这些问题都有可回放的案例。当前实验没有系统改变任务长度，没有多种子置信区间，也没有未见任务或扰动 OOD 评测；因此结论是**已识别与时序决策相关的失败机制，不是已证明长期记忆退化或跨分布性能不足**。

### 必要的适配说明

上层使用 DeepSeek V4-Pro；图像由 Flash 转写，Thea 等独立验证器另读取图像。RPent 和 CaP 的 SAM3 换成公开 Grounding DINO 与 SAM2.1；感知误差可能向后传播，替换不视为数值等价。Thea port 未部署完整场景图、真机技能和跨任务经验库；Zetta 未开展论文规模演化；CaP 使用原生单模型集成而非论文异构模型集成。

修复仅针对依赖、EGL、数据/模型接口、初态重置、动作计数和数值兼容，保留各自核心决策流程。新增接口与边界回归测试 17 项通过。调试与 canary 不计成功率；环境预算终止和合法动作失败仍计为方法失败，不因成绩低而排除。

### 复核文件

本报告使用本项目真实实验记录，不填入原论文成绩冒充实测。仓库 docs/reproduction/ 下保存详细方法与案例：

- SAM3\_FREE\_LONG\_RESULTS.md：Fixed、EmbodiedSkills、Thea port；含动作回放与输入诊断。
- RPENT\_OPEN\_LONG\_RESULTS.md：十任务结果、记忆/工具调用与真值时间线。
- ZETTA\_ONLINE\_RESULTS.md：冻结候选、三组配对结果和逐次 critic 触发。
- CAPX\_ONLINE\_RESULTS.md：原生代码闭环、逐段输出与执行图像。
- ROBOTICS\_AGENT\_RUNTIME\_ADAPTATIONS.md：保留机制、修复项与部署边界。

机器可读摘要位于 results/20260915-sam3free/ 和 results/20260915-open-agents/，含来源路径、固定版本与样本记录。服务器数据盘 experiments/coding-agent/ 保留原始图像、动作、模型输出和私有真值；API 密钥不进入报告或 Git。